Case: Nova integração de eventos de transporte

A empresa precisa integrar os eventos de transporte do TMS a um cliente estratégico e ao ERP SAP Business One, com um piloto em 90 dias. Do cenário, quatro fatos orientam a decisão: a perda de eventos atrasa o faturamento; os eventos chegam duplicados, atrasados ou fora de ordem, e algumas unidades ficam até 30 minutos sem conexão; a equipe tem dois desenvolvedores com 50% de disponibilidade, o equivalente a uma pessoa, sem estrutura para sustentar uma plataforma complexa; e as interfaces do ERP e do TMS ainda não foram verificadas.

Com 20 mil eventos por dia concentrados no horário comercial (premissa: 80% em 10 horas), a média é de cerca de 0,4 evento por segundo, e os picos de 10x chegam a 4 ou 5 eventos por segundo. É um volume baixo para qualquer fila ou banco gerenciado: o desafio aqui não é escala, e sim confiabilidade (não perder, não duplicar, tratar eventos fora de ordem e enxergar falhas). Por isso, a proposta privilegia componentes simples e gerenciados, em vez de plataformas de alta escala que exigiriam operação especializada.

Premissas adotadas

As dúvidas levantadas na análise foram tratadas com premissas explícitas, separando o que o case informa, o que assumimos e o que precisa ser validado com a empresa. O detalhamento de cada item está no material de apoio.

Tema	**Premissa ou decisão**	**A validar**
ERP SAP B1	Destino passivo, via Service Layer; recebe só eventos com efeito de faturamento; o B1if não será usado	Quais eventos geram faturamento; faturamento por entrega ou consolidado
Sistema do cliente	Recebe por push na API dele (pior caso); entrega isolada num adaptador; contrato padrão proposto	Forma e formato de recebimento; SLA; suporte a chave de idempotência
Chave dos eventos	O TMS não fornece ID; chave gerada por entrega + tipo + horário da ocorrência	Existência de ID na origem; precisão do horário
Data e hora	Dois horários (ocorrência e recebimento); ISO 8601 com fuso, atribuído pelo cadastro da unidade	Origem do horário; fuso; sincronização dos relógios
Interface do TMS	Planejamento com API; a arquitetura aceita API ou arquivos EDI; o piloto implementa uma, definida no spike	Mecanismos disponíveis; reenvio em caso de falha
Formato para cliente	JSON via API; OCOREN previsto como adaptador alternativo	Formato exigido; versão do layout e frequência

Requisitos e incertezas

Perguntas que podem mudar a decisão

Diferente das premissas acima, que afetam detalhes do desenho, estas perguntas podem mudar a escolha entre A, B e C ou o plano do piloto:

1. Quais mecanismos de integração o TMS oferece (API, webhook ou arquivos), e ele reenvia eventos em caso de falha? Define a porta de entrada, a latência possível e o esforço em qualquer alternativa.
2. Qual a versão do SAP B1, a Service Layer está disponível e licenciada, e onde o ERP roda (nuvem ou rede da empresa)? Muda o esforço do adaptador e pode exigir conectividade privada.
3. Quais eventos geram efeito no ERP, e o faturamento é por entrega ou consolidado? Muda o volume para o ERP, a latência exigida e a complexidade do adaptador.
4. Como o cliente quer receber os eventos (API dele, contrato padrão da empresa ou OCOREN), e com qual SLA? Muda o adaptador de saída e os requisitos de latência.
5. A plataforma A tem conectores comprovados para este TMS e para o SAP B1, com deduplicação e reprocessamento nativos? Se comprovado numa prova de conceito, A pode passar a ser a melhor opção.
6. O que a mensalidade de C inclui, como se dividem as responsabilidades com o parceiro, e o código e a infraestrutura ficam com a empresa no fim do contrato? Define o principal risco de C e a possibilidade de saída.
7. Qual o escopo e o horizonte da expansão (quantos clientes e integrações)? Muitas integrações diluem o custo fixo de A.
8. A empresa já tem padrão de nuvem, mensageria ou uma equipe de plataforma? Muda o custo de operação de B e C e a escolha das ferramentas.

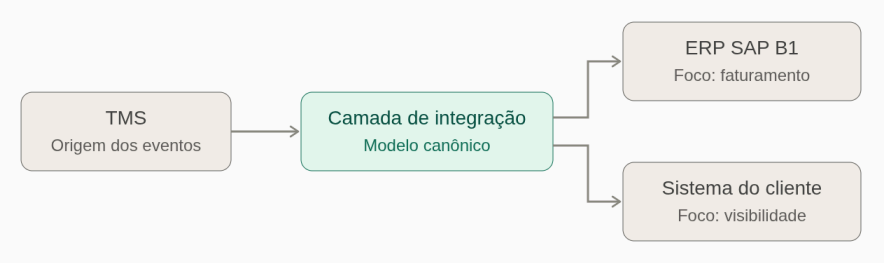
Requisitos mensuráveis

Os valores são propostas para a empresa confirmar. A última coluna indica o que depende de validação com o negócio, porque reflete expectativa de serviço ou de custo, e não um limite técnico.

Categoria	**Metas propostas**	**Depende do negócio**
Disponibilidade e latência	Entrada disponível 99,5% do mês; 95% dos eventos no cliente em até 5 min; 95% dos eventos de faturamento no ERP em até 15 min; pico de 10x sem perda, fila normalizada em até 30 min	Disponibilidade e as duas latências
Integridade, duplicidade e ordenação	Zero eventos aceitos perdidos (reconciliação diária); zero efeitos de negócio duplicados; nenhum status regredido por evento fora de ordem; 100% dos inválidos em quarentena com o motivo	Nenhum
Recuperação e reprocessamento	Unidade 30 min offline sem perda; destino 24 h fora sem perda; RPO = 0 e RTO de até 1 h; reprocessamento pela operação sem duplicar; eventos guardados por 12 meses	RTO e retenção
Segurança, acessos e rastreabilidade	Chamadas autenticadas e com TLS 1.2+; credenciais em cofre, trocadas a cada 90 dias; usuário do SAP com acesso mínimo; 100% das ações manuais registradas; dados pessoais mínimos (LGPD)	Retenção de dados pessoais
Observabilidade	100% dos eventos rastreáveis por correlation ID; alerta em até 10 min para fila de erros, fila parada ou evento parado há 15 min; painel por destino; todo alerta com roteiro	Nenhum
Custo e sustentação	Custo em 36 meses dentro da alçada; teto mensal de nuvem com alerta; até 4 h por semana de sustentação interna; novo cliente no contrato padrão em até 2 semanas	Alçada, teto de nuvem e prazo de novos clientes

A solução

Na essência, o problema envolve uma origem de eventos (TMS) e dois destinos com necessidades diferentes: o sistema do cliente, focado em visibilidade e latência, e o ERP, focado em faturamento e integridade. A ideia é não criar duas integrações ponto a ponto, e sim converter cada evento para um **modelo canônico**, tratá-lo uma única vez numa camada comum e distribuí-lo a cada destino no formato e com as regras que ele exige. Assim, as regras são escritas uma única vez, e um novo cliente ou origem exige apenas um novo adaptador, não uma nova integração.



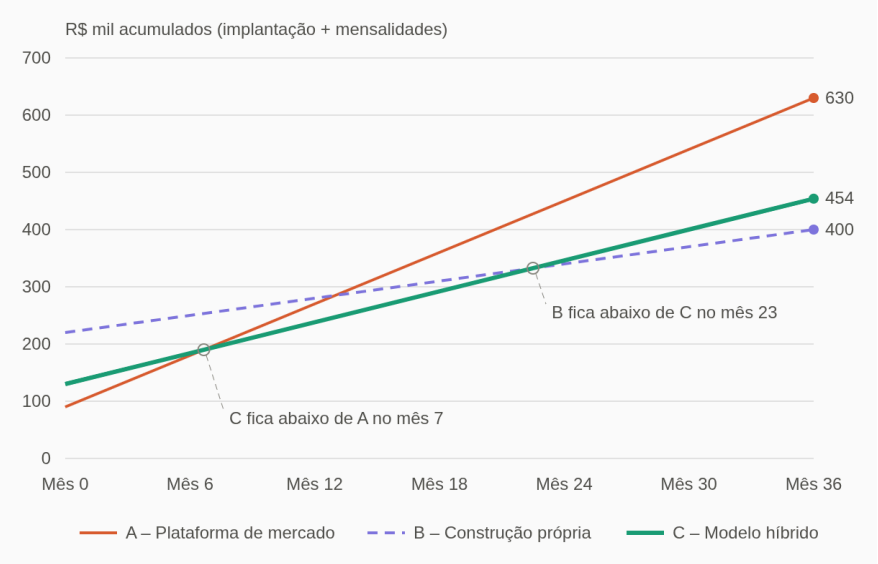
Comparação das alternativas propostas

Critério	A – Plataforma	B – Construção própria	C – Híbrido
Aderência funcional	Depende dos recursos da plataforma para deduplicação, ordem e reprocessamento, etc.	Total, pois é feita sob medida	Total nas regras do negócio, que são código próprio
Viabilidade de integração	Depende de conectores prontos para o TMS e o SAP B1, ainda não comprovados	Depende das interfaces do TMS e do SAP B1, ainda não verificadas	Mesma dependência de B, mais a conectividade entre a nuvem e o ERP
Prazo e capacidade interna	60 dias; baixa exigência da equipe	120 dias, acima do prazo; alta exigência da equipe	90 dias, sem folga; exigência média, com apoio do parceiro
Custo total em 36 meses	R$ 630 mil	R$ 400 mil	R$ 454 mil
Operação e manutenção	O fornecedor opera; a equipe acompanha pelo painel	A equipe opera tudo, infraestrutura e código	A nuvem opera a infraestrutura; a equipe opera as regras, com apoio do parceiro
Dependência e saída	Alta: os fluxos ficam no formato da plataforma	Nenhuma	Média: depende da nuvem, mas as regras são código próprio
Riscos de implantação	Conectores não cobrirem o necessário, gerando atraso e custo extra	Atraso e concentração de conhecimento	Divisão de responsabilidades com o parceiro e prazo sem folga

A incerteza sobre as interfaces do TMS e do SAP B1 afeta as três alternativas. Por isso, a verificação dessas interfaces é o primeiro passo do piloto, qualquer que seja a escolha.

Custo total em 36 meses

O custo para 36 meses foi calculado pela fórmula: **Implantação + (36 × Mensalidade)** + Custos não informados. O gráfico à seguir mostra a evolução dos custos, desde o índio (com a implantação) até o custo final (considerando os valores recorrentes já apresentados)



Esses valores acima não incluem custos que o case não informa: esforço interno de implantação e sustentação (maior em B), licença de usuário técnico no SAP B1, conectividade com o ERP, possível customização de conectores e aumento de preço por volume em A, e o custo de saída do fornecedor. A direção de cada um, por alternativa, está no material de apoio.

O custo oculto mais relevante é a sustentação de B. Por exemplo, se ela consumir 25% de um desenvolvedor sênior (premissa: R$ 30 mil por mês), são cerca de R$ 270 mil em 36 meses fora do subtotal, o que tende a anular a vantagem de custo de B. Uma estimativa preliminar também indica que a infraestrutura gerenciada de C, neste volume, custaria entre R$ 1,5 mil e R$ 3 mil por mês; entendemos, portanto, que a mensalidade de C deve incluir serviços do parceiro, o que precisa ser confirmado.

Recomendação

Recomendamos C, o modelo híbrido. A escolha não foi somente pelo custo total, mas também por:

1. **Prazo:** o piloto deve ficar pronto em 90 dias. B, com 120 dias, não atende.
2. **Capacidade de sustentação:** a equipe equivale a uma pessoa e não tem estrutura dedicada.
3. **Estabilidade da operação:** o transporte opera à noite, nos fins de semana e nos feriados, e um evento perdido atrasa o faturamento. Alguém precisa responder a uma falha a qualquer hora.
4. **Custo total e dependência de fornecedor.**

As regras da integração são construídas tanto em B quanto em C; a diferença está em quem opera a infraestrutura. Em B, disponibilidade, backups, atualizações e escala ficariam com a equipe interna, sem plantão. Em C, essa parte fica com serviços gerenciados, que já oferecem esses recursos. Por isso, mesmo que a estimativa de B se mostre menor, a recomendação se mantém: o custo menor não compensa o risco operacional neste cenário.

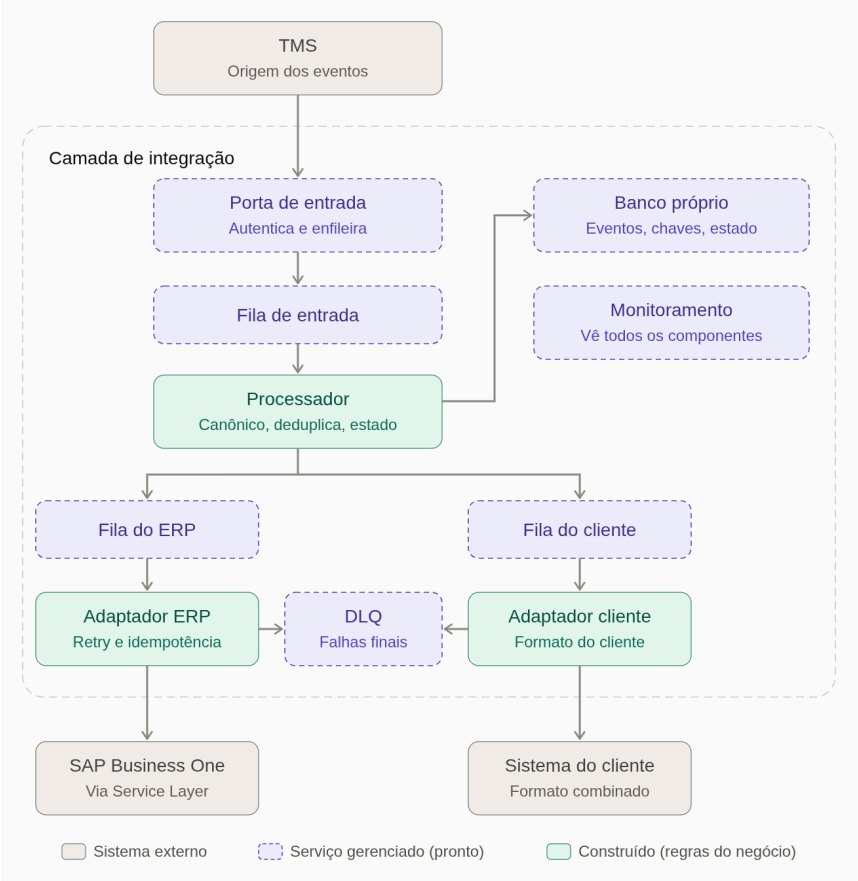
A atende ao prazo, mas é a mais cara a partir do 7º mês, depende de conectores não comprovados e coloca as regras do negócio dentro de uma plataforma de terceiros. C é a única opção que atende ao mesmo tempo prazo, capacidade e estabilidade, com custo intermediário e as regras sob controle da empresa.

O que faria mudar a decisão

- **Para A:** uma plataforma comprovadamente compatível com o nosso cenário e mais barata. Isso significa uma prova de conceito com os fluxos reais, demonstrando conectores para o TMS e o SAP B1, com deduplicação e reprocessamento nativos; um custo competitivo em 36 meses; e uma saída viável, sem prender as regras do negócio na plataforma.
- **Para B:** uma equipe maior e mais sênior, com capacidade permanente de desenvolver **e** operar a solução, inclusive fora do horário comercial. Uma equipe que apenas constrói e depois sai não resolve o problema de sustentação. Também tornaria B viável fazer a construção própria sobre serviços gerenciados, o que é um caminho natural para a fase de expansão.

Arquitetura geral

A arquitetura segue um fluxo único: os eventos entram por uma porta comum, são convertidos para o modelo canônico e tratados uma única vez, e depois seguem para cada destino por um caminho independente. Cada componente responde a um problema descrito no cenário: duplicidade, ordem, picos de volume, indisponibilidade dos destinos e dificuldade de identificar falhas.



No diagrama, cada evento entra pela porta de entrada, aguarda na fila e é tratado pelo processador, que o converte para o modelo canônico, elimina duplicatas e atualiza o estado da entrega. Depois segue para a fila de cada destino, onde um adaptador próprio entrega ao ERP ou ao cliente; falhas definitivas vão para a fila de erros (DLQ). As caixas tracejadas são serviços gerenciados de nuvem; as verdes são construídas pela equipe e concentram as regras do negócio. O monitoramento acompanha todos os componentes. O desenho segue o modelo hub-and-spoke: uma camada central trata cada evento uma única vez.

A função de cada componente e o motivo de ele existir estão no material de apoio. Os serviços podem ser oferecidos por qualquer provedor de nuvem (por exemplo, na AWS: API Gateway, SQS, Lambda, RDS e CloudWatch). A escolha final deve seguir o padrão de nuvem já adotado pela empresa.

Tratamento de falhas

Garantia de entrega. Adotamos a garantia de entrega "pelo menos uma vez" (at-least-once) em todas as etapas: da origem para a integração, dentro da integração e da integração para os destinos. Nenhum evento é descartado enquanto não houver confirmação de que foi tratado; a consequência é que um mesmo evento pode chegar mais de uma vez. Por isso, todo processamento é idempotente: repetir um evento não muda o resultado. A combinação garante que cada evento tenha efeito uma única vez, que é o que o negócio precisa.

- **Evento duplicado:** cada evento tem uma chave única (da origem ou gerada a partir dos dados). A chave é gravada de forma atômica; se já existir, o evento é descartado e o descarte fica registrado.
- **Destino indisponível:** o adaptador faz novas tentativas com intervalos crescentes. Se o destino estiver fora, o consumo é pausado e os eventos aguardam na fila, sem perda. Quando ele volta, o acumulado é entregue no ritmo que o destino suporta.
- **Falha de conectividade:** a origem guarda os eventos e reenvia ao reconectar. Os reenvios são absorvidos pela deduplicação.
- **Evento inválido ou fora de ordem:** eventos inválidos vão para quarentena com o motivo registrado. Para a ordem, vale o horário da ocorrência, e a máquina de estados impede que um evento antigo regrida o status da entrega.
- **Reprocessamento sem duplicar:** os eventos originais ficam guardados e podem ser reprocessados. A deduplicação, a máquina de estados e a verificação no ERP (se o documento com aquela referência já existe) garantem que nada seja aplicado duas vezes.
- **Monitoramento e acionamento:** cada evento é rastreado por um identificador único. Alertas disparam quando há eventos na fila de erros, filas paradas ou atrasos, e cada alerta tem um roteiro de ação para a operação.

Registro de decisão (ADR-001)

A decisão está registrada no formato ADR (contexto, alternativas, decisão, consequências e concessões, riscos e pendências, critérios de revisão) no documento ADR-001, enviado junto com este.

Plano do piloto (13 semanas)

Item	Definição
Recorte	Cliente estratégico; uma ou duas unidades, ao menos uma com histórico de falta de conexão; três ou quatro tipos de evento (coleta, em trânsito, entrega concluída e entrega não realizada); no ERP, só o evento que dispara o faturamento; uma porta de entrada, escolhida no spike.
Cronograma	Semanas 1 e 2: spike das interfaces, desenho detalhado e matriz de responsabilidades. Semanas 3 a 8: construção. Semanas 9 e 10: testes de falha (duplicata, destino fora do ar, unidade offline, pico de 10x). Semanas 11 e 12: execução em paralelo com o processo atual. Semana 13: decisão de entrada em produção.
Critérios de sucesso e entrada em produção	Na execução em paralelo: zero eventos perdidos (reconciliação diária), zero faturas duplicadas, nenhum status regredido, 95% dos eventos no cliente em até 5 minutos, falhas visíveis com alerta em até 10 minutos e ao menos um reprocessamento feito pela operação sem ajuda dos desenvolvedores. A produção exige esses resultados por duas semanas seguidas, aceite do financeiro e do cliente, roteiro de operação validado, revisão de segurança e reversão testada.
Reversão	A integração é ligada e desligada por cliente e por unidade, por configuração, e o processo manual atual segue disponível durante o piloto e as primeiras semanas em produção. Gatilhos: uma fatura duplicada, uma perda de evento confirmada ou falhas acumuladas na fila de erros sem solução por algumas horas.